Báo cáo cá nhân

Task 3 — Curate without losing evidence

Trần Thùy Dương — MSV: 24020107

Phần 1. Các bước thực hiện

Mục tiêu: làm sạch `envelopes.csv` (10 205 dòng) theo hợp đồng `research-telemetry-v1` nhưng **không làm mất dòng nào**: dòng lỗi vào `quarantine.csv`, dòng trùng vào `duplicates.csv`, dòng tốt vào `curated.parquet`.

Bước 1. Chuẩn bị. Vào pod `curate` (namespace `bd-g01`), ghi 4 file vào `/work` bằng `kubectl exec -i`: `curate.sql`, `run_curate.py`, `test_c04.py` (cùng `typed.sql` có sẵn).

Bước 2. Viết `curate.sql` (`typed.sql` ép kiểu dữ liệu trước đó):

- Gắn lỗi sớm cho từng dòng: `PARSE`, `KEY`, `INGEST_PARSE`.
- Với dòng không lỗi sớm, chọn **bản thắng** cho mỗi `record_id` (`ingest_ts` mới nhất; hòa thì `source_object`, `source_row` nhỏ hơn).
- Chỉ kiểm tra bản thắng theo thứ tự: `REQUIRED`, `NUMERIC`, `UNIT`, `RANGE`, `TIME_PARSE`, `TIME_ORDER`, `REFERENCE` (đổi °F sang °C).
- Bản thắng hợp lệ → curated (đúng 10 cột, bỏ `operator_email`, `raw_payload`); bản thắng lỗi và lỗi sớm → quarantine; bản bị thay thế → duplicates.

Bước 3. Viết `run_curate.py`: đọc tham số từ `contract.json`, chạy SQL, xuất 3 file kết quả, tự chạy kiểm tra C01 (bảo toàn dòng), C02 (đảo/xáo thứ tự đầu vào, kết quả không đổi), C03 (đúng schema, không lộ cột nhạy cảm).

Bước 4. Viết `test_c04.py`: 18 phản ví dụ trên dữ liệu nhỏ ($32\,°\mathrm{F} = 0{,}00°\mathrm{C}$, đơn vị K, `nan`, bản mới hơn nhưng lỗi, hòa thứ hạng, dòng trễ, …).

Bước 5. Chạy và thu bằng chứng: `python test_c04.py` → 18/18 đạt; `python run_curate.py --replay` → run `8c68ba1d`, C01/C02/C03 đạt. Sao chép kết quả về `~/out`.

Bước 6. Ghi hash vào `t3-hashes.json` (contract, manifest, envelopes, code, 3 file đầu ra) và kiểm tra lại bằng `sha256sum`: trùng khớp.

Kết quả chính (run `8c68ba1d`):

Chỉ tiêu	Giá trị	Ngưỡng / ghi chú
Dòng thô = curated + quarantine + duplicates	$10\,205 = 9\,610 + 395 + 200$	không mất dòng (C01)
Completeness, uniqueness, validity, registry, chronology	9 610/9 610	$= 1{,}0$
Timeliness (trễ ≤ 900 s)	$9\,410/9\,610 = 0{,}979$	$\geq 0{,}95$
Reference coverage	100/100	$= 1{,}0$
Reference agreement	$95/100 = 0{,}95$	$\geq 0{,}95$ (sát ngưỡng)

Phần 2. Cross-check bằng `c_verify_a_i03.json`

Mục đích: kiểm tra độc lập rằng dữ liệu đầu vào không bị sửa — nếu một file đầu vào bị đổi dù chỉ 1 byte thì phải bị phát hiện (`INPUT_INTEGRITY`) và bản gốc không bị ảnh hưởng.

Cách làm: với mỗi file đầu vào, kiểm tra bản gốc (trước), tạo một *bản sao bị sửa* và kiểm tra lại, rồi kiểm tra bản gốc lần nữa (sau). Đối chiếu băm với `Lab2-datasets.zip` làm nguồn tham chiếu.

File đầu vào	Gốc (trước)	Bản sao bị sửa	Gốc (sau)	Kết quả
observations_a.csv	OK	INPUT_INTEGRITY	OK	PASS
observations_b.jsonl	OK	INPUT_INTEGRITY	OK	PASS
sensors.csv	OK	INPUT_INTEGRITY	OK	PASS
qa_reference.csv	OK	INPUT_INTEGRITY	OK	PASS

Nhận xét:

- Cả 4 file đều đạt: bản gốc khớp băm, bản bị sửa bị phát hiện, bản gốc không đổi sau thử nghiệm. So với kiểm tra 103 trước đây (chỉ thử sensors.csv), lần này phủ đủ 4 file.
- **Trạng thái tổng là PARTIAL, không phải PASS.** Lý do ghi trong file: trusted_manifest.json trong /work bị ghi đè lúc 05:50 ngày 11/10 nên **không còn dùng làm chuẩn tin cậy**; phải dùng Lab2-datasets.zip thay thế.
- **Hệ quả:** t3-hashes.json có ghi băm của trusted_manifest.json, nhưng file đó không còn đáng tin. Vì vậy phần băm đầu ra (curated.parquet, …) vẫn đúng với những gì đã chạy, nhưng việc đối chiếu đầu vào phải dựa vào Lab2-datasets.zip, không dựa vào manifest cũ.
- **Việc nên làm:** khôi phục trusted_manifest.json gốc từ Lab2-datasets.zip và chạy lại cross-check để đưa trạng thái từ PARTIAL lên đầy đủ.

Các file nộp: curate.sql, typed.sql, run_curate.py, test_c04.py, curate-checks-8c68ba1d.json, c04-results.json, t3-hashes.json, c_verify_a_i03.json.