Báo cáo cá nhân – Lab 2: Data Curation, Quality & Metadata Governance

Nguyễn Hữu Cảnh - 24020044
Trường Đại học Công nghệ
Môn học: Kỹ thuật và Công nghệ dữ liệu lớn -Role B

Ngày 11 tháng 10 năm 2026

Phần 1: Authored technical work

1. Trách nhiệm và artifact: Nhiệm vụ kỹ thuật của em là Task 2, đo lường chất lượng dữ liệu. Em viết `code/quality.sql` (cùng `run_before.py`, `run_after.py`, `plot_chart.py`), định nghĩa các metric với cohort và mẫu số tường minh, và xuất bằng chứng trước/sau curation: `quality_before.json`, `quality_after.json`, `quality_chart.png`, `defect_report.md`. Bối cảnh: run `8c68ba1d`, hợp đồng `research-telemetry-v1`, AS_OF `2026-02-09T00:00:00Z`. Commit: `4ef7b92`.

2. Thay đổi em tự viết:

- Các view `typed`, `key_eligible`, `winners`. Bản thắng được chọn bằng `ROW_NUMBER()` theo `ingest_ts DESC, source_object ASC, source_row ASC`, nên kết quả không phụ thuộc thứ tự file.
- Quần thể trước curation W là tập winners trước bước lọc hợp lệ, không phải toàn bộ dữ liệu thô. Số lượng thô (10 205), lỗi parse (5), khóa sai (20), thời gian nhận không đọc được (20) và trùng lặp dư (200) được báo riêng để các phần bị loại vẫn nhìn thấy.
- Các điều kiện kiểm tra trước curation tại 'w_flags' sử dụng 'COALESCE(..., FALSE)' để xem kết quả 'NULL' là không đạt. Các metric dùng 'COUNT(*) FILTER (WHERE ...)' để đếm số bản ghi đạt trên cohort đã xác định. Tỉ lệ trả về 'NULL' với trạng thái 'NOT_EVALUATED' khi mẫu số bằng 0.
- Độ đồng thuận và độ phủ tham chiếu tính trên bản curated: đồng thuận = số ID khớp trong ±0,05 °C chia số ID được ghép; độ phủ = số ID được ghép chia 100. `qa_reference.csv` chỉ dùng để đo, không dùng để sửa hay chọn giá trị.

3. Kết quả đo (tính từ SQL):

Rule	Trước curation	Sau curation	Cohort
Q_REQUIRED	9850/9960 (0,989)	9610/9610 (1,000)	W / curated
Q_UNIQUE	9960/10160 (0,980)	9610/9610 (1,000)	key-eligible / curated
Q_VALUE	9710/9960 (0,975)	9610/9610 (1,000)	W / curated
Q_REFINT	9930/9960 (0,997)	9610/9610 (1,000)	W / curated
Q_TIME	9890/9960 (0,993)	9610/9610 (1,000)	W / curated
Q_TIMELY	9690/9890 (0,980)	9410/9610 (0,979)	dòng có chronology hợp lệ
Q_REF_AGREE	–	95/100 (0,950)	ID tham chiếu được ghép
Q_REF_COVERAGE	–	100/100 (1,000)	toàn bộ 100 ID tham chiếu

Kiểm tra nhất quán: $9610 + 395 + 200 = 10\,205$ và $9960 - 350 = 9610$. Bốn nhóm lỗi trên winners (REQUIRED 110, VALUE 140, TIME 70, REFERENCE 30) cộng đúng 350; 200 bản ghi trễ được giữ lại và gắn cờ.

4. Kiểm thử: `code/test_quality_edgecases.py` dựng một fixture 10 bản ghi có kết quả tính tay: giá trị trống, 300 °C, đơn vị K, cảm biến lạ, event sau ingest, bản mới không hợp lệ đè bản cũ hợp lệ, khóa sai và 32 °F bằng 0 °C. Kỳ vọng: Q_REQUIRED 7/8, Q_UNIQUE 8/9, Q_VALUE 4/8, Q_REFINT 7/8, Q_TIME 7/8, Q_TIMELY 6/7; $W = 8$, trùng lặp dư 1; bản thắng của `R000008` phải là dòng 9 (bản mới không hợp lệ), không được lùi về bản cũ. Với đầu vào rỗng, mọi metric phải là `NOT_EVALUATED`. Kết quả chạy ngày 2026-10-11: `OVERALL: PASS`, cả 11/11 test đều đạt. Kết quả chi tiết được lưu tại `evidence/b-unit-test-quality.json`.

5. Giải thích quyết định thiết kế:

- **Mẫu số của Q_UNIQUE là key-eligible (10 160) chứ không phải W:** trên W mỗi `record_id` đã duy nhất theo cách xây dựng, nên độ duy nhất luôn là 100% và che mất 200 bản ghi trùng. Đánh đổi là các metric có cohort khác nhau, vì vậy mỗi bản ghi metric nêu rõ cohort, chú thích biểu đồ liệt kê mọi quần thể và em không gộp các chiều thành một điểm duy nhất.

- **NULL tính là lỗi, mẫu số 0 là `NOT_EVALUATED`:** nếu viết `WHERE temperature BETWEEN ...` thì NULL bị loại khỏi mẫu số và completeness tăng giả; nếu mẫu số bằng 0 mà trả 100% thì một bước lọc hỏng toàn bộ sẽ trông như dữ liệu hoàn hảo.

- **Các metric đạt 100% sau curation là do loại dòng, không phải do phục hồi dữ liệu:** giữ lại $9610/10\,205 = 94{,}2\%$ bản ghi thô và $9610/9960 = 96{,}5\%$ quần thể W. Q_TIMELY giảm nhẹ từ 0,9798 xuống 0,9792 chỉ vì mẫu số thu hẹp ($9890 \to 9610$); cả trước và sau đều có 200 bản ghi trễ, được giữ lại.

- **Đồng thuận 95/100 đúng bằng ngưỡng 0,95:** không còn dư địa, và chỉ mô tả mẫu 100 ID được cung cấp, không chứng minh độ chính xác của mọi cảm biến. Loại một ID không khớp sẽ làm đồng thuận đẹp hơn nhưng vi phạm điều kiện độ phủ 100/100.

Một lỗi em đã gặp khi làm và cách em sửa: Trong quá trình xây dựng metric, em nhận ra việc lọc bỏ các bản ghi lỗi trước khi tổng hợp có thể làm sai mẫu số và khiến tỷ lệ chất lượng cao hơn thực tế. Em điều chỉnh bằng cách giữ nguyên cohort, dùng `COUNT(*) FILTER (WHERE ...)` để đếm số bản ghi đạt và dùng `count(*)` để xác định mẫu số. Với mẫu số bằng 0, em trả về `NULL` và trạng thái $\texttt{NOT}_E VALUATED$.

Phần 2: Independent hands-on check

1. Đối tượng và lệnh: Em kiểm tra độc lập đầu ra của Role C (24020107): candidate/cur quarantine.csv, duplicates.csv. Lệnh: python3 crosscheck_conservation.py 24020044 24020107, bằng chứng lưu tại evidence/b-crosscheck-conservation.json. Kiểm tra dùng EXCEPT/INTERSECT trên khóa vật lý (source_object, source_row) thay vì chỉ so tổng số dòng, vì hai tổng bằng nhau vẫn có thể che giấu một bản ghi bị mất cùng một bản ghi bị nhân đôi.

2. Dự đoán (viết trước khi chạy):

- $9\,610+395+200 = 10\,205$; không có bản ghi bị mất, bị tạo thêm hoặc bị chồng lấn giữa ba đầu ra.

- Mọi bản ghi thắng trong view winners của em đều nằm trong curated hoặc quarantine (0 bản ghi thiếu).

- Các dòng trong curated ∪ quarantine mà không phải winner có đúng $5 + 20 + 20 = 45$ dòng (quarantine trước bước khóa).
- duplicates.csv đúng bằng tập key-eligible trừ winners (200 dòng), kiểm tra hai chiều.
- record_id là duy nhất trong curated.

3. Kết quả quan sát (chạy ngày 2026-10-11, DuckDB 1.5.5, đầu vào dựng lại từ Lab2-datasets.zip và xác minh hash theo trusted_manifest.json; hash envelopes.csv 28d633f0...cc7, trùng envelopes_sha256 trong t3-hashes.json của Role C):

- Số lượng: raw 10 205; curated 9 610; quarantine 395; duplicates 200; tổng khớp. Mất 0, tạo thêm 0, chồng lấn curated-quarantine, curated-duplicates và quarantine-dupl đều bằng 0; khóa vật lý trùng trong cả ba đầu ra bằng 0; record_id trùng trong curated bằng 0.
- Winners của em so với đầu ra của Role C: winner không nằm trong curated hoặc quarantin 0; dòng trong curated ∪ quarantine mà không phải winner: 45, đúng bằng 45 kỳ vọng (5+20+20); bản thay thế thiếu trong duplicates: 0; dòng trong duplicates không phải bản thay thế: 0.
- Cả 8 check đều đạt (PASS = true). Hash candidate: curated.parquet 17b163b2..., quarantine.csv f40c76db..., duplicates.csv 64eed4ba..., trùng với output_sha256 trong t3-hashes.json của Role C.
- Tái lập: chạy lại run_before.py và run_after.py cho quality_before.json và quality_aft giống hệt các tệp đã lưu (diff không có khác biệt).

4. Đối chứng âm: để chứng minh check có khả năng phát hiện lỗi, test_quality_edgecase dựng một phân hoạch sai: 5 bản ghi thô, curated $\{1, 2\}$, quarantine $\{3\}$, duplicates $\{4, 4\}$ (mất bản ghi 5, nhân đôi bản ghi 4). Tổng $2 + 1 + 2 = 5$ vẫn bằng số bản ghi thô, nhưng check EXCEPT phải báo mất 1 và trùng 1; phân hoạch đúng $\{4, 5\}$ thì phải báo 0 và 0. Kết quả: cả hai test đều PASS. Với phân hoạch sai, tổng số bản ghi đầu ra vẫn bằng tổng số bản ghi đầu vào nhưng phép kiểm tra phát hiện 1 bản ghi bị thiếu và 1 bản ghi bị trùng. Với phân hoạch đúng, phép kiểm tra phát hiện 0 bản ghi bị thiếu và 0 bản ghi bị trùng.

5. Diễn giải: Kết quả trùng với toàn bộ năm dự đoán, không có chênh lệch nào. Bằng chứng này mạnh hơn việc so tổng số dòng vì phép EXCEPT/INTERSECT phát hiện được trường hợp mất một bản ghi và nhân đôi một bản ghi khác mà tổng vẫn khớp (xem đối chứng âm). Vì view winners do em tự xây dựng, việc khớp với đầu ra của Role C cho thấy hai cách cài đặt chọn cùng một tập bản thắng.

6. Giới hạn của các bằng chứng kiểm tra: Việc các check đều đạt chỉ chứng minh được tính nhất quán giữa hai cách cài đặt. Nó không chứng minh được những điều sau:

1. Quy tắc được hiểu đúng: Em và Role C cùng đọc một hợp đồng; nếu cả hai hiểu sai cùng một quy tắc thì check vẫn đạt.
2. Độ chính xác của phép đo: Một giá trị nằm trong khoảng $[-30, 60]$ °C vẫn có thể sai so với thực tế; tỉ lệ đồng thuận 95/100 chỉ áp dụng cho mẫu tham chiếu 100 ID được cung cấp.
3. Tái lập byte-for-byte: Việc so sánh dựa trên tập khóa vật lý và nội dung logic, không dựa trên byte của tệp Parquet.

4. Môi trường chạy: Đầu vào được dựng lại ở máy cục bộ từ Lab2-datasets.zip và xác minh theo trusted manifest, còn candidate lấy từ máy ảo của nhóm; đây không phải lần chạy trực tiếp trong pod.