BÁO CÁO CÁ NHÂN – LAB 2
HỌC PHẦN: KỸ THUẬT VÀ CÔNG NGHỆ DỮ LIỆU LỚN

Họ và tên: Nguyễn Hữu Thành Đạt
Mã sinh viên: 24020062
Vai trò đảm nhiệm: Role D – Metadata Governance
Repository: `bigdata-cloud-lab2`
Nhánh làm việc (Branch): `role-d-metadata`
Nhiệm vụ chính: Metadata, Lineage, Retention

---

1 Công việc được phân công

Trong bài Lab 2, tôi đảm nhiệm vai trò **Role D – Metadata Governance**. Nhiệm vụ trọng tâm gồm:

- Xây dựng và kiểm tra tính hợp lệ của metadata catalog cho các sản phẩm dữ liệu sau quá trình curation.
- Thiết lập thông tin OpenLineage và chứng minh khả năng truy vết nguồn gốc dữ liệu (data traceability).
- Xây dựng chính sách vòng đời dữ liệu (retention policy) và soạn thảo tài liệu hướng dẫn (`README.md`).
- Thực hiện kiểm tra độc lập (Independent Check) đối với quy trình Release Gate của Role E.

Phần việc của tôi được thực hiện tiếp nối sau khi các thành viên phụ trách Ingestion, Quality và Curation đã tạo ra các artifact cần thiết. Toàn bộ thông số metadata (số dòng, schema, mã băm SHA256) được tôi trích xuất tự động từ kết quả thực tế của pipeline, không nhập thủ công.

2 Xây dựng và kiểm tra Metadata Catalog

2.1 Xây dựng ba catalog tương ứng ba phân lớp dữ liệu

Dựa trên các schema và template chuẩn (`metadata_catalog_schema.json`, `catalog_template.json`), tôi tạo 3 tệp catalog JSON phản ánh đúng ba trạng thái dữ liệu trong pipeline:

- **Raw intake** (`metadata/raw_catalog.json`): Dữ liệu đầu vào thô sau khi chuyển đổi thành `envelopes.csv`.
- **Quarantine** (`metadata/quarantine_catalog.json`): Các bản ghi không đạt yêu cầu validation chất lượng.
- **Curated** (`metadata/curated_catalog.json`): Tập dữ liệu sạch hoàn thiện (`curated.parquet`) làm candidate cho release.

Kết quả cân bằng số lượng bản ghi: Pipeline ghi nhận tổng cộng 10,205 bản ghi đầu vào, chia thành: 9,610 bản ghi curated, 395 bản ghi quarantine và 200 bản ghi duplicate. Tổng số bản ghi đầu ra bằng đúng 10,205 ($9,610 + 395 + 200 = 10,205$), chứng minh pipeline không bị thất thoát dữ liệu.

2.2 Kiểm tra tính hợp lệ của Metadata

Tôi xây dựng hai script kiểm thử tự động độc lập:

- **Kiểm tra cấu trúc (`code/validate_catalog.py`):** Sử dụng thư viện `jsonschema` để kiểm tra định dạng và các trường bắt buộc theo schema. Cả ba catalog (raw, quarantine, curated) đều vượt qua bước này.
- **Kiểm tra ngữ nghĩa thực tế (`code/validate_catalog_semantic.py`):** Đối chiếu thông tin khai báo trong metadata với file vật lý trên đĩa (kiểm tra lại số dòng, danh sách cột và tính toán lại mã băm SHA256 của file `curated.parquet`). Kết quả đối chiếu hoàn toàn trùng khớp.

3 Lineage và khả năng truy vết nguồn gốc (Traceability)

Tôi xây dựng các OpenLineage event (`START` và `COMPLETE`) cho tiến trình curation, mô tả quan hệ giữa các input (`observation`, `sensor registry`, `contract`) với các output (`curated.parquet`, `quarantine.csv`, `duplicates.csv`).

Để chứng minh khả năng truy vết dữ liệu, tôi thực hiện hai phép trace mẫu:

1. **Bản ghi hợp lệ (Curated):** Một bản ghi trong `curated.parquet` được truy ngược về đúng file nguồn ban đầu, số dòng tương ứng và mã băm SHA256 của file nguồn đó.

2. **Bản ghi bị loại (Quarantine):** Bản ghi mã `R000001` trong `quarantine.csv` được truy vết về dữ liệu raw, xác định rõ nguyên nhân bị loại ở bước `WINNER_VALIDATION` với mã lỗi `REQUIRED` (thiếu trường bắt buộc theo contract).

Toàn bộ log truy vết được lưu lại làm minh chứng tại thư mục `evidence/T4/`.

4 Chính sách lưu trữ và Tài liệu hóa dữ liệu

- **Chính sách lưu trữ (`metadata/retention-plan.json`):** Quy định thời gian lưu trữ cho từng loại: Raw data giữ trong 30 ngày, Quarantine giữ trong 7 ngày, và Approved release giữ trong 90 ngày. Chính sách có xử lý ngoại lệ cho các trường hợp *legal hold* hoặc dữ liệu đang được một release hoạt động tham chiếu. Quá trình kiểm tra retention được thực hiện ở chế độ `dry-run` an toàn, không xóa dữ liệu thật.
- **Tài liệu kỹ thuật (`docs/CURATED_DATASET_README.md`):** Mô tả mục đích sử dụng, nguồn gốc, schema chi tiết, quy trình curation, báo cáo chất lượng, giới hạn sử dụng và cam kết thời gian lưu trữ nhằm phục vụ người dùng downstream.

5 Kiểm tra độc lập (Independent Check – Role E Release Gate)

Theo yêu cầu kiểm tra chéo, Role D kiểm tra khả năng bắt lỗi của Role E (Release Gate) khi nhận metadata bị thiếu thông tin:

- **Kịch bản kiểm thử (Case P05):** Trường thông tin `steward` bị loại bỏ có chủ đích khỏi metadata của candidate dataset.
- **Kết quả mong đợi:** Release Gate phải từ chối candidate với lý do `REJECT / METADATA`.
- **Kết quả thực tế:** Gate của Role E phát hiện chính xác lỗi thiếu `steward` và trả về mã từ chối hợp lệ. Kết quả này được lưu riêng tại file `evidence/T4/independent_check_p05.json`.

6 Danh mục minh chứng kỹ thuật

Đường dẫn trong repository	Mô tả nội dung / Mục đích
`metadata/raw_catalog.json`	Catalog cho dữ liệu đầu vào thô (`envelopes.csv`).
`metadata/quarantine_catalog.json`	Catalog cho dữ liệu bị cách ly (`quarantine.csv`).
`metadata/curated_catalog.json`	Catalog cho dữ liệu sạch hoàn thiện (`curated.parquet`).
`code/validate_catalog.py`	Script kiểm tra hợp lệ cấu trúc metadata theo JSON Schema.
`code/validate_catalog_semantic.py`	Script đối chiếu metadata với tệp vật lý (SHA256, shape).
`lineage/curation_*.json`	OpenLineage events mô tả dòng chảy dữ liệu (START/COMPLETE).
`evidence/T4/lineage_trace_*.json`	Bằng chứng truy vết ngược bản ghi hợp lệ và bản ghi R000001.
`metadata/retention-plan.json`	Chính sách vòng đời dữ liệu (Raw 30d, Quarantine 7d, Release 90d).
`evidence/T4/independent_check_p05.json`	Log kiểm tra chéo Role E từ chối candidate thiếu steward.
`docs/CURATED_DATASET_README.md`	Hướng dẫn sử dụng và lược đồ chi tiết của Curated dataset.

7 Kết luận

Toàn bộ phần việc của Role D đã hoàn thành đầy đủ trên nhánh `role-d-metadata` trước khi tích hợp vào nhánh chính của nhóm. Các artifact và script đều được kiểm thử, phản ánh đúng dữ liệu thực tế từ pipeline.

Qua bài lab, tôi hiểu rõ tầm quan trọng của metadata và data lineage: một sản phẩm dữ liệu chỉ thực sự hoàn chỉnh khi có đầy đủ siêu dữ liệu kèm theo để người sử dụng có thể kiểm chứng được chất lượng, nguồn gốc và điều kiện sử dụng trước khi đưa vào khai thác.